**Centro Universitário SENAI SC- Campus Florianópolis**

**CURSO DE GRADUAÇÃO EM CIÊNCIA DE DADOS E INTELIGÊNCIA ARTIFICIAL**

# PLANO DE TRABALHO

## PROJETO INTEGRADOR

**Equipe:**

**Samuel Silva de Rezende - LÍDER / PRODUCT OWNER**

**Vinícius Joacir dos Anjos**

**Guilherme da Silva Anselmo**

**Guilherme Zamboni Menegacio**

**FLORIANÓPOLIS / SC**

**AGOSTO / 2026**

| DETALHAMENTO DO PROJETO | |
|---|---|
| **Tema do Projeto:** | Radar ENEM: produto de dados interativo para diagnóstico estatístico comparativo a partir dos Microdados do ENEM no período da pandemia de COVID-19 (edições 2019, 2020, 2021 e 2022) |
| **Equipe:** | **Samuel Silva de Rezende** - Matrícula: 2192212 - (48) 99225-6892 - samuel_s_rezende@estudante.sesisenai.org.br - LÍDER DA EQUIPE / PRODUCT OWNER<br><br>**Vinícius Joacir dos Anjos** - Matrícula: 2175294 - (48) 991733710 - vinicius_j_anjos@estudante.sesisenai.org.br - LÍDER DE DESENVOLVIMENTO E IA<br><br>**Guilherme da Silva Anselmo** - Matrícula: 2182147 - (49) 99128-6316 - guilherme_s_anselmo@estudante.sesisenai.org.br - QA, VALIDAÇÕES, INTEGRIDADE E SEGURANÇA<br><br>**Guilherme Zamboni Menegacio** - Matrícula: 1786392 - (48) 98847-8084 - guilherme_menegacio@estudante.sesisenai.org.br - DESIGN, FRONTEND E SUPORTE |
| **Turma:** | 4ª FASE - 444311 - Projeto Aplicado III |
| **Curso:** | Bacharelado em Ciência de Dados e Inteligência Artificial |
| **Líder Técnico (orientador):** | Gustavo Stangherlin Cantarelli |
| **Coorientadores:** | Hugo Menezes Barra<br>Fernando Ramos Lengler<br>Cláudio Rapôso<br>Felipe Sovernigo<br>Marco Aurélio Silva Areas |

## CONTEXTO:

Os Microdados do ENEM são publicados pelo INEP e trazem, para cada participante, as notas das quatro áreas e da redação ao lado das respostas do questionário socioeconômico: renda familiar, escolaridade dos pais, tipo de escola, município, raça/cor. Este projeto trabalha com quatro edições - 2019, 2020, 2021 e 2022 - que somadas passam de 6 GB de CSV descompactado.

O intervalo não foi escolhido por acaso. A edição de 2019 é a última antes da pandemia de COVID-19; 2020 e 2021 são os anos de escola fechada e ensino remoto; 2022 é a primeira retomada. O próprio exame registra o tamanho do choque: em 2020, dos 5.523.029 inscritos na versão impressa, 2.842.332 não apareceram, uma abstenção de 51,5% contra 23% no primeiro dia de 2019. Em 2021 o número de inscritos caiu para 3.109.762, o menor desde 2005, enquanto a abstenção do primeiro dia recuou para 26% (INEP, 2021). Em 2022, com 3.396.632 inscritos, a

abstenção do primeiro dia foi de 26,7% (INEP, 2022). O choque aparece em duas dimensões distintas: a taxa de comparecimento voltou ao patamar de 2019 já em 2021, mas a base de inscritos encolheu 44% entre 2020 e 2021 e não havia se recomposto em 2022. Mudou a nota e mudou também a composição de quem prestou o exame, o que impede tratar as quatro edições como populações equivalentes.

Antes de qualquer análise, o arquivo exige uma série de decisões. Separar quem compareceu aos dois dias de quem faltou. Definir o tratamento dos treineiros. Traduzir os códigos do questionário em categorias legíveis. Estabelecer, para cada recorte, o número mínimo de participantes abaixo do qual a comparação deixa de fazer sentido. Trabalhar com quatro edições acrescenta duas exigências: harmonizar variáveis que mudaram de nome ou saíram da base ao longo do período, e converter as faixas de renda em múltiplos do salário mínimo, já que o valor de referência subiu de R$ 998 em 2019 para R$ 1.212 em 2022. Nenhuma dessas escolhas é automática, e todas alteram o resultado final.

O participante recebe suas notas, mas não recebe contexto. Uma nota de 620 em Matemática não diz se está acima ou abaixo da mediana de quem declarou a mesma faixa de renda, nem quantas pessoas formam esse grupo de comparação, nem como essa mesma posição se comportava em 2019. A informação está nos microdados e é pública, mas hoje só chega a quem sabe manipular alguns gigabytes de CSV. O Radar ENEM existe para encurtar essa distância.

Do lado técnico, o obstáculo é de arquitetura. Ler o CSV inteiro a cada consulta leva minutos, e quem abre uma página web espera segundos. A separação entre processamento em lote e sistema de atendimento a consultas é o padrão descrito por Kleppmann (2017) para cargas analíticas com restrição de latência: o processamento pesado roda uma vez, fora do ar, e produz artefatos comprimidos; a aplicação online apenas consulta esses artefatos, sem carregar a base bruta na memória. Isso também é o que permite hospedar o produto em infraestrutura gratuita, com cerca de 1 GB de RAM.

O projeto reúne o que foi visto em Big Data, Computação em Nuvem, Engenharia de Dados MLOps e Estatística I, com Projeto Aplicado III como eixo integrador, na 4ª fase do curso de Ciência de Dados e Inteligência Artificial do UniSENAI/SC - Campus Florianópolis. Governança, rastreabilidade de autoria e testes entram desde o primeiro sprint, e não como ajuste final antes da entrega.

Uma ressalva delimita o alcance do produto: o Radar ENEM é um instrumento descritivo. Ele mostra posição relativa dentro de cada edição analisada, nada além disso. Percentil não é probabilidade de aprovação, diferença entre grupos não é prova de causa, e variação entre 2019 e 2022 não isola o efeito da pandemia de tudo o mais que mudou no período.

**OBJETIVOS:**

GERAL:
Projetar, implementar, validar e implantar em nuvem o Radar ENEM, produto de dados web de acesso público que traduz as notas e o perfil socioeconômico informados pelo usuário em posicionamento estatístico comparativo dentro das edições de 2019 a 2022 do ENEM.

ESPECÍFICOS:

1. Caracterizar empiricamente as quatro edições dos Microdados do ENEM (2019 a 2022) por meio de profiling de volume, estrutura, tipos, cardinalidades, ausências e distribuição das variáveis relevantes, formalizando um contrato e um dicionário de dados para o projeto.

2. Realizar pesquisa e benchmarking das alternativas tecnológicas candidatas (pandas, Polars, DuckDB, Spark quando pertinente; Parquet; Streamlit, Dash ou React/FastAPI; opções de nuvem), justificando a stack segundo memória, escalabilidade, desempenho, complexidade operacional, custo e adequação ao prazo.

3. Construir pipeline de dados offline e reprodutível, com camadas RAW/TRUSTED/ANALYTICS, seleção de colunas, tipagem, tratamento explícito de ausências, regras de elegibilidade, relatório de qualidade, linhagem, hash da fonte, versionamento da execução e geração de artefatos colunares comprimidos.

4. Medir e documentar a volumetria e o desempenho do pipeline e das consultas, comparando um baseline simples com a solução otimizada e registrando métricas de tamanho, tempo, memória e latência das consultas representativas.

5. Implementar um motor estatístico comum e testado, contemplando distribuição empírica, média, mediana, variância, desvio-padrão, percentis, Z-Score e representações gráficas adequadas; utilizar intervalos de confiança e testes de hipótese apenas quando metodologicamente pertinentes e com premissas explícitas.

6. Definir e desenvolver quatro módulos autorais de análise comparativa, um por integrante, cada um com regras de negócio próprias, entradas dinâmicas, população/grupo de referência documentado, tratamento de empates e ausências, validações, testes e autoria rastreável.

7. Construir uma interface web responsiva e acessível, com storytelling de dados, visualizações de distribuição, indicação do tamanho do grupo de referência,

explicações metodológicas e mensagens claras para casos inválidos ou insuficientes.

8. Implantar uma versão beta em nuvem antes da etapa final, evoluindo para uma versão pública estável até a AV6, com monitoramento básico, proteção de segredos, validação de entradas e política de não persistência dos dados informados pelo usuário.

9. Aplicar práticas de Gestão Ágil e DataOps/MLOps compatíveis com o escopo: backlog, Kanban, sprints, RACI, registro de riscos, ADRs/decisões, Pull Requests, CI, releases por avaliação, testes automatizados, Definition of Done e controle de mudanças.

10. Produzir as três publicações extensionistas e a documentação acadêmica exigida, preservando ética, confidencialidade, identidade institucional e coerência entre código, metodologia, resultados, relatórios e apresentação final.

**JUSTIFICATIVA:**

Relevância social. O projeto busca democratizar uma leitura estatística que normalmente exige conhecimento técnico para ser produzida. Ao contextualizar a nota do participante dentro de distribuições e recortes sociodemográficos, o Radar ENEM transforma microdados públicos em informação interpretável para estudantes, famílias, educadores e demais interessados, favorecendo compreensão crítica de desigualdades educacionais sem atribuir causalidade indevida aos fatores observados.

Relevância do recorte temporal. O intervalo de 2019 a 2022 é o objeto do estudo, e não uma limitação de disponibilidade. A pandemia interrompeu o ensino presencial de forma desigual entre quem tinha e quem não tinha computador e internet em casa, e o próprio exame registra o tamanho da ruptura: a abstenção do primeiro dia passou de 23% em 2019 para 51,5% em 2020 e retornou a 26% em 2021, enquanto o número de inscritos caiu de 5,5 milhões em 2020 para 3,1 milhões em 2021.Comparar quatro edições permite observar se as distâncias entre grupos socioeconômicos se abriram, se mantiveram ou se fecharam no período, algo que uma edição isolada não revela.

Relevância técnica. O desafio envolve simultaneamente grande volume de dados, restrição de memória, compactação, consulta analítica, qualidade, governança, backend estatístico e implantação em nuvem. A solução deverá demonstrar que processamento pesado pode ser deslocado para uma etapa offline reprodutível,

permitindo que o runtime web opere sobre estruturas otimizadas e responda com baixo custo e latência adequada.

Relevância científico-estatística. O valor do produto depende da correção das definições utilizadas. Percentil, Z-Score, média, dispersão, tamanho do grupo e eventuais procedimentos inferenciais serão documentados e testados com casos controlados. O projeto diferenciará população observada da edição, amostra, recorte e inferência, preservará a semântica de valores ausentes e evitará transformar medidas descritivas em probabilidades ou previsões não sustentadas pelos dados.

Integração curricular. As competências relacionadas a seguir correspondem às unidades curriculares da 4ª fase (SENAI/SC, 2026). Big Data fundamenta processamento em escala, ETL, particionamento e avaliação de infraestrutura; Engenharia de Dados MLOps fornece governança, pipelines, versionamento, DataOps, qualidade, segurança e monitoramento; Estatística I sustenta a amostragem quando necessária, medidas descritivas, distribuições, inferência e representação gráfica; Computação em Nuvem orienta modelo de implantação, armazenamento, custo, segurança e operação; Gestão Ágil estrutura escopo, cronograma, recursos, riscos, mudanças e melhoria contínua; Projeto Aplicado III integra essas competências no ciclo completo do produto.

Ética, privacidade e responsabilidade. Serão utilizados exclusivamente microdados públicos disponibilizados pelo INEP. Os dados inseridos na interface pelo usuário serão processados apenas para produzir o resultado da sessão e não serão persistidos como perfil individual, em observância aos princípios de finalidade, necessidade e não discriminação estabelecidos pela Lei nº 13.709/2018 (BRASIL, 2018). A aplicação informará o tamanho do grupo comparado, as limitações da análise e o caráter observacional dos resultados. Segredos, credenciais e configurações de infraestrutura não serão versionados no repositório.

Viabilidade. O projeto priorizará tecnologias de código aberto e serviços com cota gratuita ou baixo custo, evitando infraestrutura desnecessariamente complexa. Recursos distribuídos, Spark em cluster, NoSQL, streaming, modelos de Machine Learning ou IA generativa somente serão incorporados ao núcleo se a pesquisa técnica demonstrar necessidade real e benefício mensurável; caso contrário, permanecerão fora do MVP.

**PLANO ESTRUTURAL (escopo):**

1. Metodologia de desenvolvimento e governança

O projeto será conduzido de forma iterativa e incremental (HIGHSMITH, 2012), com sprints curtas e marcos diretamente associados às avaliações da UC. O quadro oficial de trabalho será mantido no GitHub Projects em fluxo Kanban (GITHUB, [s.d.]) (Backlog, Ready, Em andamento, Em revisão, Bloqueado e Concluído). Haverá sincronização semanal da equipe, revisão ao final de cada sprint e registro de mudanças relevantes em ADRs (Architecture/Analysis Decision Records).

A branch main representará versões estáveis; a branch engineering concentrará o pipeline e a engenharia de dados exigidos na AV3; cada módulo autoral terá branch própria/feature branch com commits do respectivo autor. Toda integração relevante ocorrerá por Pull Request revisado por pelo menos um integrante diferente do autor. Releases/tags serão criadas nos principais marcos (AV2, AV3, AV4/AV6 e AV7).

A Definition of Done de uma tarefa técnica exigirá, conforme aplicável: código ou artefato funcional; testes executados; atualização da documentação; evidência/benchmark; revisão por outro integrante; ausência de credenciais; e vínculo com issue/requisito. Mudanças de escopo, stack ou metodologia estatística deverão registrar motivo, impacto e decisão aprovada pelo Product Owner.

Será produzido um Business Model Canvas simplificado (OSTERWALDER; PIGNEUR, 2011) como artefato interno de planejamento, contemplando usuários, proposta de valor, canais, recursos, parceiros, custos e benefícios sociais, sem finalidade comercial obrigatória.

2. Papéis e responsabilidades da equipe

Samuel Silva de Rezende - Líder da equipe / Product Owner. Responsável pela visão do produto, escopo, priorização, documentação, cronograma, integração entre as UCs, reuniões, riscos, critérios de aceite, AV1/AV6/portfólio e coordenação da banca. Sua atuação de desenvolvimento será concentrada no módulo autoral exigido pela AV4 e em integrações excepcionais, preservando autoria individual.

Vinícius Joacir dos Anjos - Líder de Desenvolvimento e IA. Responsável por arquitetura técnica, organização do código, engine compartilhada, pipeline/serviços, automação, CI, apoio ao deploy e avaliação de tecnologias de IA apenas quando justificadas. Lidera decisões de desenvolvimento, mas não substitui a autoria individual dos módulos.

Guilherme da Silva Anselmo - QA, Validações, Integridade e Segurança. Responsável pela estratégia de testes, qualidade de dados, contratos, regras de

integridade, validação de inputs, testes estatísticos controlados, regressão, segurança básica, privacidade, auditoria de dependências e critérios de aceite. Apoia engenharia e módulos sem assumir autoria alheia.

Guilherme Zamboni Menegacio - Design, Frontend e Suporte. Responsável por arquitetura de informação, experiência do usuário, identidade visual, interface, visualizações, acessibilidade, mensagens de erro e integração visual dos módulos. Atua também no suporte à integração e documentação de UX.

Observação de autoria AV4: cada integrante será o único responsável e desenvolvedor da lógica específica de seu módulo comparativo. Componentes compartilhados (ETL, engine estatística, validações comuns, design system e infraestrutura) poderão ser reutilizados, porém regras, testes e commits do módulo deverão demonstrar autoria do respectivo responsável.

Matriz RACI resumida

Produto, escopo e documentação: Samuel A/R; Vinícius C; Anselmo C; Zamboni C.

Arquitetura e stack: Samuel A; Vinícius R; Anselmo C; Zamboni C.

Pipeline/Big Data: Vinícius R; Anselmo R em QA; Samuel C; Zamboni C.

Motor estatístico comum: Vinícius R pelo desenvolvimento compartilhado; Anselmo R pela validação; Samuel A pelas regras e aceite; Zamboni C.

QA, integridade e segurança: Anselmo A/R; demais consultados conforme frente.

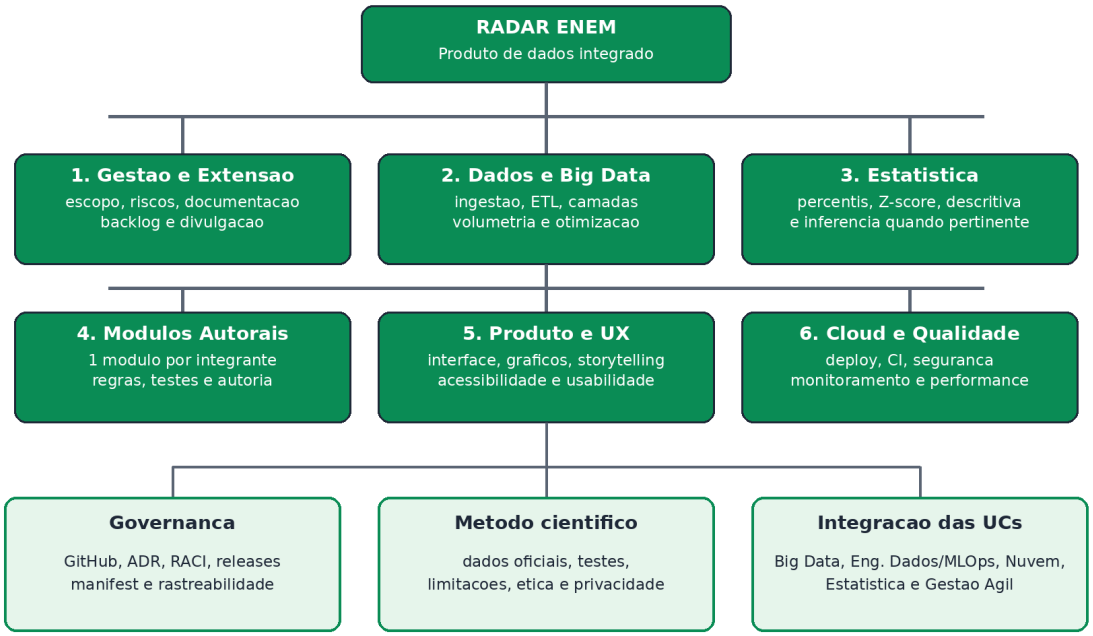
Frontend, UX e visualização: Zamboni A/R; Samuel A pelo aceite de produto; Vinícius e Anselmo C.

Cloud, CI e release: Vinícius R; Samuel A; Anselmo e Zamboni C.

Portfólio extensionista: Samuel A/R; equipe C e fornecedora de evidências.

Módulo autoral individual: Cada integrante é A/R por seu próprio módulo.

Legenda: R = responsável pela execução; A = accountable/aprovação final; C = consultado.




4. Arquitetura de dados e stack tecnológica - hipótese inicial

A arquitetura será validada por benchmark antes de ser considerada definitiva. A hipótese inicial prioriza Python 3.12, Polars para transformação eficiente/lazy quando aplicável, Parquet com compressão ZSTD como formato analítico, DuckDB para consultas OLAP sobre arquivos colunares e Streamlit + Plotly como caminho de menor complexidade para o MVP. A hipótese apoia-se na especificação do formato colunar e do esquema de compressão (APACHE SOFTWARE FOUNDATION, [s.d.]), no modelo de execução lazy da biblioteca de transformação (POLARS, [s.d.]), na proposta de banco analítico embarcado sem servidor externo (RAASVELDT; MÜHLEISEN, 2019) e no modelo de execução por reprocessamento de script da camada de interface (STREAMLIT, [s.d.]). Dash e uma arquitetura React + FastAPI permanecerão como alternativas de frontend/backend a serem comparadas conforme UX, esforço de integração e implantação. Spark poderá compor o benchmark conceitual ou experimental de Big Data, mas não será adotado em produção sem necessidade mensurável.

Camadas previstas: RAW (arquivo oficial preservado, dicionário e hash); TRUSTED (dados tipados, validados e com regras explícitas de elegibilidade); ANALYTICS (artefatos, agregados e estruturas de consulta preparados para o motor estatístico). O processamento pesado ocorrerá offline. O runtime web não deverá reler ou materializar o CSV bruto a cada requisição.

A implantação será testada antecipadamente em provedor com cota gratuita ou baixo custo. Streamlit Community Cloud e Hugging Face Spaces serão avaliados para o MVP; contêiner em serviço serverless/gerenciado será plano alternativo caso memória, compatibilidade ou controle de runtime exijam. Custos, limites e disponibilidade serão reavaliados na data do deploy, evitando assumir que uma cota gratuita é permanente.

5. Plano de dados, qualidade e rastreabilidade

• Fonte oficial: Microdados do ENEM 2019, 2020, 2021 e 2022 e respectivos dicionários disponibilizados pelo INEP. O arquivo original será preservado e identificado por hash SHA-256.

• Profiling inicial: volume bruto/descompactado, linhas, colunas, tipos, cardinalidades, valores ausentes, distribuição das notas, presença nas provas e variáveis candidatas a recorte.

• Contrato de dados: para cada campo utilizado serão documentados nome INEP, nome interno, tipo, domínio/categorias, regra de ausência, transformação, elegibilidade e módulos consumidores.

• Funil de qualidade: toda exclusão relevante deverá ser contabilizada por motivo; não serão usados drop/inner joins silenciosos que impossibilitem explicar perdas de registros.

• Semântica: ausência, prova não realizada, categoria não informada e valor zero serão tratados como estados distintos quando o dicionário permitir diferenciá-los.

• Manifesto de execução: execution_id, data/hora, ano do dataset, hash da fonte, commit/versão do pipeline, linhas de entrada/saída/rejeitadas, tamanhos, duração e artefatos gerados.

• Reprodutibilidade: mesma entrada + mesma versão do pipeline e metodologia deverá gerar resultado logicamente equivalente; fixtures sintéticas serão mantidas no repositório, sem versionar o dataset completo

6. Plano estatístico e de validação científica

Sempre que computacionalmente viável, as comparações de produção utilizarão a população elegível de cada edição para o recorte definido, e não uma amostra arbitrária. Caso amostragem seja necessária para profiling, benchmark ou alguma inferência, o método de amostragem, tamanho e erro serão documentados conforme Estatística I.

• Medidas descritivas: média, mediana, moda quando pertinente, variância, desvio-padrão, quartis e tamanho do grupo de referência, conforme as definições de Bussab e Morettin (2017).

• Representações: histogramas, boxplots e outras visualizações adequadas à distribuição e à pergunta do módulo.

• Percentil: definição empírica explícita e testada sobre a distribuição observada (BUSSAB; MORETTIN, 2017), incluindo regra para empates; não será tratado como probabilidade de aprovação.

• Z-Score: calculado apenas quando desvio-padrão e população/grupo estiverem bem definidos; sua interpretação será separada de percentil.

• Inferência: intervalos de confiança e testes de hipótese serão usados apenas em comparações em que premissas, pergunta e significado sejam adequados; resultados observacionais não serão apresentados como causalidade. As premissas de cada procedimento — independência das observações, tamanho de grupo e distribuição de referência — serão verificadas antes da aplicação (DEVORE, 2011).

• Grupos pequenos: será definido, após profiling e discussão estatística, um limiar mínimo de grupo/referência ou regra de alerta. A interface informará n e não ocultará insuficiência de dados.

• Validação: funções estatísticas serão testadas com datasets sintéticos de resultado conhecido, incluindo empates, grupo vazio, desvio zero, valor extremo e ausências.

7. Requisitos preliminares

RF01 - Permitir que o usuário informe nota(s) do ENEM e os atributos necessários ao módulo selecionado.

RF02 - Calcular e apresentar estatísticas da população/grupo de referência, incluindo n, medidas de tendência/dispersão, percentil e Z-Score quando aplicável.

RF03 - Disponibilizar quatro módulos comparativos autorais e entradas dinâmicas específicas.

RF04 - Exibir visualizações e explicações metodológicas do resultado, com indicação de limitações.

RF05 - Tratar entradas inválidas, categorias inexistentes, grupos insuficientes e dados não disponíveis sem falha da aplicação.

RF06 - Disponibilizar aplicação web pública e gratuita no contexto acadêmico/extensionista.

RNF01 - Não carregar o CSV bruto completo no runtime de cada consulta; utilizar artefatos/consultas otimizadas.

RNF02 - Meta de desempenho: consultas representativas com tempo de resposta de até 3 s no ambiente-alvo, a ser validada por benchmark; resultados fora da meta deverão ser analisados e documentados.

RNF03 - Manter pipeline reproduzível, versionamento, testes, rastreabilidade e autoria no GitHub.

RNF04 - Não persistir os dados pessoais/contextuais informados pelo usuário como perfil individual.

RNF05 - Aplicar princípios básicos de segurança, acessibilidade, clareza, responsividade e monitoramento.

8. Módulos autorais e responsáveis

Samuel - Equidade socioeconômica. Comparar a nota do usuário com participantes da mesma faixa de renda e com um grupo de contraste socioeconômico definido a partir do dicionário do ENEM. Samuel será autor da regra, documentação, testes e código específico do módulo, ainda que sua função principal seja de Product Owner.

Vinícius - Recorte territorial. Comparar o desempenho com UF, região e referência nacional/geral da edição, com análise das diferenças de distribuição e tamanho dos grupos.

Guilherme Anselmo - Capital escolar familiar. Comparar o usuário por escolaridade dos responsáveis ou variável equivalente disponível no questionário, com forte controle de categorias, ausências, integridade e tamanho de grupo.

Guilherme Zamboni - Rede de ensino de origem. Comparar participantes por rede/tipo de escola e agregado, priorizando visualização clara entre distribuições e experiência de interação.

As definições finais de campos e categorias dependerão do dicionários oficiais das quatro edições. Qualquer alteração de módulo ou responsável após a AV1 deverá ser registrada no Decision Log e preservar a exigência de autoria individual.

9. Escopo incluído

• Quatro edições de produção: ENEM 2019 a 2022, com possibilidade de arquitetura preparada para futuras edições sem processá-las simultaneamente neste semestre.

• Pipeline offline, profiling, contrato de dados, quality report, manifesto de execução, compactação e benchmark.

• Motor estatístico comum, quatro módulos autorais, interface web, visualizações e deployment público.

• GitHub com governança, testes, CI/release, documentação técnica, relatórios e portfólio extensionista.

• Análise de viabilidade técnica/econômica, segurança, privacidade, riscos, limitações e monitoramento básico.

10. Escopo excluído

• Predição de nota futura, previsão de aprovação no SISU/Prouni ou recomendação de curso baseada em probabilidade não validada.

• Treinamento obrigatório de modelos de Machine Learning, IA generativa ou chatbot; IA poderá ser avaliada apenas como melhoria futura após o núcleo estar validado.

• Reidentificação de participantes, armazenamento de perfis individuais inseridos pelos usuários ou coleta de dados pessoais além do necessário para a sessão.

• Aplicativo móvel nativo, autenticação de usuários, pagamentos, infraestrutura corporativa de alta disponibilidade ou banco gerenciado pago como requisito do MVP.

• Streaming contínuo, Kafka, Hadoop/Spark em cluster, NoSQL, replicação multirregião e balanceamento avançado sem necessidade comprovada por benchmark.

11. Cronograma de execução por sprint e marcos

10/08-25/08 | Sprint 0 - Planejamento. AV1; AV5.1; definição do recorte 2019–2022; escopo; papéis; backlog; EAP; riscos; pesquisa inicial de stack. Responsável principal: Samuel; equipe participa. Marco: AV1 + AV5.1 em 25/08.

26/08-08/09 | Sprint 1 - Fundação de dados. Download/verificação; profiling; contrato de dados; baseline CSV; hash; arquitetura RAW/TRUSTED/ANALYTICS; POC de cloud. Liderança técnica: Vinícius; QA: Anselmo; produto: Samuel.

09/09-22/09 | Sprint 2 - ETL e vertical slice. ETL v1; Parquet; benchmark de pandas/Polars/DuckDB e Spark se pertinente; engine estatística v0; shell da interface e design system. Vinícius/Anselmo/Zamboni; aceite de Samuel.

23/09-29/09 | Sprint 3 - MVP parcial. Primeiro fluxo ponta a ponta: input -> consulta -> estatística -> visualização; evidências e slides. Equipe completa. Marco: AV2 em 29/09.

30/09-13/10 | Sprint 4 - Engenharia consolidada. Freeze da fundação de dados; quality report; manifest; volumetria; benchmark; arquitetura; requisitos; governança GitHub; publicação intermediária. Vinícius + Anselmo; Samuel consolida documentação. Marcos: AV3 + AV5.2 em 13/10.

14/10-27/10 | Sprint 5 - Estatística e módulos v1. Engine estatística v1; regras dos quatro módulos; fixtures sintéticas; módulos v1; cloud beta. Cada integrante responde por seu módulo.

28/10-10/11 | Sprint 6 - Integração beta. Módulos v2; interface integrada; acessibilidade; validação; segurança; performance; revisão de riscos e custos. Zamboni e Anselmo lideram suas frentes; equipe integra.

11/11-24/11 | Sprint 7 - Release candidate. Aplicação pública estável; relatório autoral AV4; AV6; testes finais; evidências; documentação e limitações. Samuel coordena e cada integrante entrega evidência autoral. Marcos: AV4 + AV6 em 24/11.

25/11-01/12 | Sprint 8 - Banca. Freeze de release; correções críticas; ensaio; backup de demo; slides; perguntas e respostas. Equipe completa. Marco: AV7 em 01/12.

02/12 | Sprint 9 - Encerramento extensionista. Publicação final com resultados, solução e encerramento. Samuel coordena com evidências fornecidas por toda a equipe. Marco: AV5.3 em 02/12.

Janelas de atraso do AVA (máximo de 60% da atividade): AV1/AV5.1 até 01/09; AV2 até 06/10; AV3/AV5.2 até 20/10; AV4/AV6 até 01/12; AV7 até 08/12; AV5.3 até 09/12. O planejamento interno considera exclusivamente as datas de 100% como metas.

12. Matriz de riscos e respostas

Dataset exceder memória/tempo - Probabilidade média / impacto alto. Baseline, processamento offline, seleção de colunas, Parquet, lazy/SQL analítico, pré-agregação e benchmark. Dono: Vinícius.

Limites ou custos do provedor cloud - média/alto. POC antecipada, medição de RAM/disco, alternativa em contêiner e ausência de dependência obrigatória de banco pago. Donos: Vinícius e Samuel.

Erro de definição estatística - média/alto. Metodologia documentada, casos sintéticos, revisão de QA e distinção explícita entre percentil, Z-Score e probabilidade. Donos: Anselmo e Samuel.

Perda silenciosa de registros - média/alto. Quality funnel, joins/filtros explícitos, contagem por motivo e testes de invariantes. Dono: Anselmo.

Atraso de módulo individual - média/alto. Backlog por autor, marcos v1/v2, branch própria e revisão semanal; reduzir escopo antes de transferir autoria. Dono: Samuel.

Conflito de autoria da AV4 - baixa/alto. Um responsável/desenvolvedor por módulo, commits/PRs rastreáveis e componentes compartilhados separados. Dono: Samuel.

Interpretação social inadequada - média/alto. Linguagem observacional, tamanho de grupo explícito, limitações e revisão ética/comunicacional antes de publicar. Donos: Samuel e Zamboni.

Falha de deploy ou banca - média/alto. Release freeze, smoke test, versão local e gravação de contingência, monitoramento do link. Donos: Vinícius e Zamboni.

Mudança relevante de escopo/stack - média/médio. ADR, análise de impacto em prazo/custo e aprovação do Product Owner, priorizando critérios de avaliação. Dono: Samuel.

13. Critérios de aceite e evidências planejadas

- Dados: fonte oficial identificada e hash registrada; contrato e dicionário; contagem de entrada/saída; quality report e ausência de perdas silenciosas.

- Engenharia: pipeline executável e versionado; Parquet/artefato otimizado; arquitetura documentada; métricas de volumetria, memória e tempo.

- Estatística: funções validadas por testes controlados; regras de empate/ausência/documentação; n do grupo exibido; limitações explícitas.

• Módulo autoral: input dinâmico, regra própria, validação, testes, visualização, capítulo autoral e commits do responsável.

• Aplicação: fluxo ponta a ponta, mensagens de erro, UX consistente, URL pública, meta de desempenho avaliada e ausência de persistência de perfil do usuário.

• Governança: main estável, engineering branch, PRs, tags/releases, README, ADRs, riscos, autoria e documentação sincronizada com o estado do código.

• Extensão: posts institucionais coerentes com o estado real do projeto, sem divulgar informações indevidas e com identificação exigida pela UC.

**RESULTADOS:**

Ao final do projeto, espera-se alcançar os seguintes resultados:

1. Aplicação web Radar ENEM publicada em nuvem, com link público, fluxo ponta a ponta e quatro módulos comparativos funcionais.

2. Dataset analítico otimizado a partir dos Microdados do ENEM 2019 a 2022, com redução de volumetria, dicionário/contrato de dados e arquitetura RAW/TRUSTED/ANALYTICS documentados.

3. Pipeline de ETL reprodutível, com manifesto de execução, quality report, rastreabilidade da fonte, versionamento, testes e métricas de desempenho.

4. Motor estatístico comum, testado e documentado, com medidas descritivas, percentis, Z-Score e métodos inferenciais apenas quando pertinentes.

5. Quatro módulos autorais com regras de negócio, validação, interface e evidência de autoria no GitHub: Samuel (equidade socioeconômica), Vinícius (recorte territorial), Anselmo (capital escolar familiar) e Zamboni (rede de ensino).

6. Relatório técnico de engenharia, relatório final científico-tecnológico, AV4 autoral, slides, evidências e três publicações extensionistas coerentes com o estado do produto.

7. Benchmarks que permitam demonstrar quantitativamente o ganho da arquitetura escolhida em comparação com um baseline simples, incluindo tamanho, tempo, memória e latência.

8. Conjunto de artefatos de governança - RACI, backlog, ADRs, riscos, releases, README e documentação - capaz de explicar decisões, alterações e responsabilidades ao longo do semestre.

Conclusão esperada: demonstrar que um grande conjunto público pode ser transformado em produto analítico de impacto social com rigor estatístico, desempenho e baixo custo, sem recorrer a previsões ou interpretações que excedam a evidência dos dados. O resultado deverá comprovar a integração prática das UCs do semestre e a capacidade da equipe de planejar, construir, validar, implantar, documentar e defender um produto de dados completo.

**REFERÊNCIAS:**

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Brasília, DF: Presidência da República, 2018.

INSTITUTO NACIONAL DE ESTUDOS E PESQUISAS EDUCACIONAIS ANÍSIO TEIXEIRA (INEP). Microdados do Enem. Edições 2019, 2020, 2021 e 2022. Brasília, DF: INEP. Disponível em: https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/microdados/enem. Acesso em: 25 ago. 2026.

SENAI/SC. Plano de Ensino - Projeto Aplicado III - 4ª fase. Bacharelado em Ciência de Dados e Inteligência Artificial. Florianópolis, 2026/2.

BUSSAB, Wilton O.; MORETTIN, Pedro A. **Estatística básica**. 9. ed. São Paulo: Saraiva, 2017.

DEVORE, Jay L. Probabilidade e estatística: para engenharia e ciências. São Paulo: Cengage Learning, 2011.

KLEPPMANN, Martin. Designing Data-Intensive Applications. Sebastopol: O'Reilly Media, 2017.

RAASVELDT, Mark; MÜHLEISEN, Hannes. DuckDB: an embeddable analytical database. Proceedings of SIGMOD 2019. New York: ACM, 2019.

APACHE SOFTWARE FOUNDATION. Apache Parquet Documentation. Disponível em: https://parquet.apache.org/docs/. Acesso em: 25 ago. 2026.

POLARS. Polars User Guide. Disponível em: https://docs.pola.rs/. Acesso em: 25 ago. 2026.

STREAMLIT. Streamlit Documentation. Disponível em: https://docs.streamlit.io/. Acesso em: 25 ago. 2026.

OSTERWALDER, Alexander; PIGNEUR, Yves. **Business Model Generation**: inovação em modelos de negócios. Rio de Janeiro: Alta Books, 2011.

HIGHSMITH, Jim. Gerenciamento ágil de projeto: criando produtos inovadores. Rio de Janeiro: Alta Books, 2012.

GITHUB. GitHub Docs - Pull requests, Projects e Actions. Disponível em: https://docs.github.com/. Acesso em: 25 ago. 2026.

INSTITUTO NACIONAL DE ESTUDOS E PESQUISAS EDUCACIONAIS ANÍSIO TEIXEIRA (INEP). **74% dos inscritos participam do primeiro dia de Enem**. Brasília, DF: INEP, 21 nov. 2021. Disponível em: https://www.gov.br/inep/pt-br/assuntos/noticias/enem/74-do-inscritos-participam-do-primeiro-dia-de-enem. Acesso em: 25 ago. 2026.

**EQUIPAMENTOS NECESSÁRIOS**

(MÁQUINAS E ACESSÓRIOS)

| Nome do Equipamento | Quantidade / Hora |
|---|---|
| Notebook dos integrantes (8 GB RAM, SSD 256 GB) | 4 un. / duração do projeto |
| Armazenamento local/externo para RAW, TRUSTED, ANALYTICS e backups | min. 30 GB / duração do projeto |
| Laboratório de informática do UniSENAI | 1 un. / conforme necessidade |
| Ambiente de nuvem para POC, beta e produção acadêmica | 1 serviço / duração do deploy |
| Repositório GitHub (organização da equipe) | 1 un. / duração do projeto |
| Conexão de internet e navegador atualizado | 4 acessos / duração do projeto |
| | |
| | |
| | |

**INSUMOS NECESSÁRIOS**

(CONSUMÍVEIS)

| Item | Qtd. | Valor Unitário | Valor Total |
|---|---|---|---|
| Hospedagem em nuvem (camada gratuita) | 1 | R$ 0,00 | R$ 0,00 |
| Microdados do ENEM (dados abertos INEP) | 1 | R$ 0,00 | R$ 0,00 |
| Bibliotecas e ferramentas de código aberto (Python, Polars, DuckDB, Streamlit) | 1 | R$ 0,00 | R$ 0,00 |
| Repositório GitHub (plano gratuito para estudantes) | 1 | R$ 0,00 | R$ 0,00 |
| Energia elétrica e conexão de internet (recurso próprio dos integrantes) | 4 | R$ 0,00 | R$ 0,00 |
| | | | |
| | | | |
| | | | |
| | | | |
| | | | |
| | | | |
| | | | |
| | | | |
| **CUSTO TOTAL DO PROJETO:** | | | R$ 0,00 |

| APROVAÇÃO DO PROJETO | |
|---|---|
| **Orientador:** | Nome: Gustavo Stangherlin Cantarelli<br><br>Assinatura: _____ |